Doyun Kim

M.S. Student
Soongsil University
Department of Software
Email: doyunkim@soongsil.ac.kr
Home: https://doyun-coding.github.io/
GitHub: https://github.com/Doyun-coding
LinkedIn: https://www.linkedin.com/in/doyun-kim-99aab4347/
Lab: https://sites.google.com/view/ssu-nlp

LIFELONG RESEARCH OBJECTIVE

My lifelong research objective is to understand the fundamental mechanisms of artificial intelligence and develop AI systems that are inherently safe, reliable, and trustworthy. Rather than relying solely on external safeguards, I aim to identify the underlying causes of model behaviors and security vulnerabilities through mechanistic understanding, and translate these insights into fundamental approaches for building safer and more capable AI systems.

RESEARCH INTERESTS

Large Language Models, LLM Security, AI Safety, LLM Interpretability, Self-Evolving Agents, Parameter-level Analysis

EDUCATION

- **Soongsil University** Sep. 2026 – Present
  M.S. student, Department of Software (advisor: Chanjun Park)
  GPA: 0/4.5
- **Soongsil University** Feb. 2020 – Aug. 2026
  B.S., School of Computer Science (advisor: Chanjun Park)
  GPA: 3.7/4.5

WORK EXPERIENCES

- **Natural Language Processing Lab, Soongsil University** Sep. 2026 – Present
  Graduate Researcher
- **Natural Language Processing Lab, Soongsil University** Sep. 2025 – Aug. 2026
  Undergraduate Researcher

PUBLICATIONS

Equal contribution: *, *Corresponding author*: †

Google Scholar: https://scholar.google.com/citations?user=hdxjSnIAAAAJ
Semantic Scholar: doyunkim@soongsli.ac.kr

International

1. **EvoSkill Injection: Red-Teaming Autonomous Skill Generation and Evolution in Self-Evolving Agents**
   Doyun Kim, Chanwoo Kim, Sugyeong Eo, Yeo Chan Yoon†, Chanjun Park†
   EMNLP 2026, Oral

Domestic

1. **KoEvoSkillBench: 자기진화형 에이전트의 스킬 주입 보안을 위한 한국어 벤치마크**
   Doyun Kim, Chanwoo Kim, Seonghyun Cho, Jiwoo Geum, Eunseo Song, Jihoon Song, Chanjun Park†
   Annual Conference on Human and Cognitive Language Technology (HCLT), 2026 — **Best Paper Award**

2. **한국어 LLM Judge는 의미를 보존하는가? 척도와 응답 순서에 대한 표현 불변성 분석**
   Chanwoo Kim, Doyun Kim, Minsu Song, Sihyeon Lee, Jihoon Song, Chanjun Park†
   Annual Conference on Human and Cognitive Language Technology (HCLT), 2026

3. **다중 에이전트 토론을 활용한 언어모델의 한국어 추론 오류 진단**
   Jiwoo Geum, Minsu Song, Chanwoo Kim, Sihyeon Lee, Doyun Kim, Chanjun Park†
   Annual Conference on Human and Cognitive Language Technology (HCLT), 2026

4. **지식 충돌 상황에서 대화 맥락이 대규모 언어 모델의 입장 선택과 설명에 미치는 영향**
   Jihoon Song, Chanwoo Kim, Doyun Kim, Jiyun Jang, Chaerin Nam, Chanjun Park†
   Annual Conference on Human and Cognitive Language Technology (HCLT), 2026

5. **K-Press: 한국어 벤치마크 능력 프로파일링을 위한 문항 기반 능력 축 유도**
   Jiyun Jang, Seonghyun Cho, Doyun Kim, Jihoon Song, Kyojun Choo, Jiwoo Geum, Chanjun Park†
   Annual Conference on Human and Cognitive Language Technology (HCLT), 2026

6. **소프트웨어 취약점 탐지 성능 향상을 위한 LLM 기반 코드 가젯 생성 및 정제**
   Doyun Kim, Chanjun Park†
   Korea Software Congress (KSC), 2025

Award

1. **Best Paper Award, Annual Conference on Human and Cognitive Language Technology (HCLT), 2026**
   KoEvoSkillBench: 자기진화형 에이전트의 스킬 주입 보안을 위한 한국어 벤치마크

Research Projects

Soongsil University

- 2026년 인공지능 말평 운영 및 연계 행사 개최 (2026, 참여연구자 (용역과제), National Institute of the Korean Language)
- 2026년 인공지능의 한국어 능력 표준 평가 과제 구축 및 활용 (2026, 참여연구자 (용역과제), National Institute of the Korean Language)
- 우수연구 신진연구 (유형B) (2026-2029, 참여연구자 (3책5공), NRF)

- Foundation Model 운용과정에서 민감정보 추론 방지 및 리스크 평가 기술 개발 (2026-2028, 참여연구자 (3책5공), Korea Internet & Security Agency (한국인터넷진흥원))
- 토론과 소통으로 지식을 연결하는 AI 에이전트 기술 개발 (2026-2028, 참여연구자 (3책5공), Korea Creative Content Agency(한국콘텐츠진흥원))
- AI 보안 특화 'AI 에이전트' 개발 선행 연구 (2026, 참여연구자 (용역과제), 한국정보보호학회 산하 AI보안연구회)
- 국가·공공기관 가이드라인 준수를 위한 AI 시스템 보안 위협 자동화 기술점검 도구 개발 (2026, 참여연구자, KIST)
- AI 연구용 컴퓨팅 지원 프로젝트 (파라미터 수준의 정보 제어 원천기술 연구 및 파라미터 스튜디오 플랫폼 개발) (2026, 참여연구자, KETI)
- 숭실대 신진 연구 (2025 2026, 참여연구자, Soongsil University)

External Activities

Soongsil University

- 데이터베이스 보안, [Teaching Assistant] (2026)
- SaRangAXConnect, AI Transformation (AX) Program (Fall 2026)

PATENTS

Domestic Patent Applications

- **Method and Apparatus for Verifying Security of Artificial Intelligence Agents**
  인공지능 에이전트 보안 검증 방법 및 장치
  Chanjun Park, Doyun Kim
  Korean Patent Application, filed on August 26, 2026 (Application No. 10-2026-0161210).
- **Method and Apparatus for Automatic Evaluation of Large Language Models Based on Numerical Score Topology Analysis**
  수치형 점수 토폴로지 분석 기반 대규모 언어 모델 자동평가 방법 및 장치
  Chanjun Park, Doyun Kim
  Korean Patent Application, filed on August 26, 2026 (Application No. 10-2026-0161159).
- **Method and Apparatus for Analyzing Parameter Regions of Large Language Models**
  대규모 언어 모델의 파라미터 영역 분석 방법 및 장치
  Chanjun Park, Doyun Kim, Seonghyun Cho
  Korean Patent Application, filed on August 6, 2026 (Application No. 10-2026-0146874).
- **Method, Apparatus, and System for Evaluating Security Vulnerabilities of Self-Evolving Agents**
  자가진화형 에이전트의 보안 취약성 평가 방법, 장치 및 시스템
  Chanjun Park, Doyun Kim
  Korean Patent Application, filed on June 30, 2026 (Application No. 10-2026-0119810).

MEDIA COVERAGE

MEDIA COVERAGE

- **Chosun Ilbo**, Sep. 2026.
  숭실대 김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **Soongsil University Alumni Association**, Sep. 2026.
  김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **Dong-A Ilbo**, Sep. 2026.
  숭실대 김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **Financial News**, Sep. 2026.
  숭실대 학부생 논문, 자연어처리 국제학술대회 EMNLP 2026 채택

- **Point Daily**, Sep. 2026.
  숭실대 김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **ETNews**, Sep. 2026.
  숭실대 김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **Smart Economy**, Sep. 2026.
  "공격자처럼 생각하고 스스로 진화하는 AI"… 숭실대 학부생, 글로벌 보안 판 흔들었다
- **Asia Times**, Sep. 2026.
  김도윤 숭실대 학부연구생, AI 에이전트 보안 연구 EMNLP 채택
- **Financial News**, Sep. 2026.
  스스로 배운다던 AI, 해킹 수법까지 익혀 쓴다… 신종 보안 구멍 찾았다
- **Veritas Alpha**, Sep. 2026.
  숭실대 김도윤 학부연구생 논문 자연어처리 국제학술대회 EMNLP 2026 채택
- **Hangil Times**, Sep. 2026.
  김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **SSU:catch**, Sep. 2026.
  김도윤 학부연구생, AI 에이전트 보안 연구 EMNLP 2026 채택
- **PhantomByte**, Sep. 2026.
  Your Agent Wrote Its Own Skills. Now the Compromise Never Leaves.
- **RocketPunch**, Sep. 2026.
  숭실대 학부생 연구팀, 자기진화형 AI 에이전트 보안 취약점 규명